Phân tích cảm xúc văn bản tiếng Việt
Proposal – Nhóm 6 – Đề tài 6

Trịnh Kế Toàn MSSV: 24022469
Nguyễn Văn Tùng MSSV: 24022487
Trần Hoàng Vũ MSSV: 24022494

1 Giới thiệu và phát biểu bài toán

Phân tích cảm xúc giúp nhà trường và doanh nghiệp tổng hợp ý kiến người dùng từ khối lượng bình luận lớn. Với tiếng Việt, bài toán khó hơn vì ranh giới từ không trùng với khoảng trắng (mỗi khoảng trắng chỉ ngăn cách một âm tiết), văn bản mạng có teencode, viết thiếu dấu, và phân tích cảm xúc theo khía cạnh.
Đầu vào: một câu phản hồi tiếng Việt x.
Đầu ra: nhãn y thuộc {tiêu cực, trung tính, tích cực} cùng phân phối xác suất $P(y \mid x)$.
Nhóm đặt ra ba mục tiêu nghiên cứu chính: (i) xây dựng và so sánh hiệu quả của ba phương pháp phân loại cảm xúc gồm TF-IDF kết hợp Logistic Regression, BiLSTM sử dụng word2vec/fastText tiếng Việt và PhoBERT; (ii) đánh giá ảnh hưởng của việc tách từ tiếng Việt đến hiệu quả của ba phương pháp phân loại cảm xúc trên; (iii) phân tích khả năng xử lý các biến thể văn bản tiếng Việt trong thực tế như teencode, văn bản không dấu. Bên cạnh đó, nhóm dự kiến mở rộng sang phân tích cảm xúc theo khía cạnh sản phẩm.

2 Dữ liệu

Nhóm dùng UIT-VSFC, bộ phản hồi của sinh viên về môn học và giảng viên, khoảng 16.175 câu. Mỗi câu có hai nhãn: cảm xúc (3 lớp) và chủ đề (4 lớp: giảng viên, chương trình đào tạo, cơ sở vật chất, khác). Nhóm dùng chia train/dev/test do tác giả công bố; thống kê thực tế ở Bảng 1.

Tập	Số câu	Tiêu cực	Trung tính	Tích cực
Train	11.426	46.6%	4.0%	49.4%
Dev	1.583	44.5%	4.6%	50.9%
Test	3.166	44.5%	5.3%	50.2%

Bảng 1: Thống kê số lượng và phân bố nhãn cảm xúc của tập dữ liệu UIT-VSFC (cập nhật từ dữ liệu thực tế trên Hugging Face).

Tiền xử lý. Chuẩn hóa Unicode NFC, chuyển chữ thường, giữ dấu câu. Với biến thể *có tách từ*, nhóm dùng VnCoreNLP; biến thể *âm tiết* giữ nguyên văn bản.
Rủi ro: nhãn lệch lớp (lớp trung tính ít), miền dữ liệu hẹp (giáo dục), và nhãn chủ đề chỉ là khía cạnh mức thô, không có cặp khía cạnh–cảm xúc mịn.

3 Phương pháp dự kiến

Nhóm dự kiến triển khai và so sánh ba phương pháp phân loại cảm xúc văn bản tiếng Việt, bao gồm TF-IDF kết hợp Logistic Regression, BiLSTM sử dụng word2vec/fastText và PhoBERT . Các mô hình được huấn luyện và đánh giá trên cùng bộ dữ liệu, sử dụng cách phân chia tập huấn luyện, validation và kiểm thử thống nhất nhằm bảo đảm tính công bằng trong so sánh.

TF-IDF + Logistic Regression: Được lựa chọn làm baseline truyền thống nhờ tính đơn giản, chi phí tính toán thấp và khả năng biểu diễn đặc trưng thống kê của văn bản. TF-IDF chuyển văn bản thành vector đặc trưng (n-gram 1–2, tinh chỉnh hệ số điều chuẩn C trên tập dev bằng thư viện `scikit-learn`), sau đó Logistic Regression dự đoán xác suất thuộc ba lớp cảm xúc: tích cực, tiêu cực và trung tính.

BiLSTM + word2vec/fastText: Đại diện cho phương pháp học sâu dựa trên mạng nơ-ron hồi tiếp hai chiều (triển khai tự cài bằng PyTorch). Văn bản được biểu diễn bằng các vector từ tiếng Việt (embedding fastText 300 chiều), sau đó BiLSTM (1–2 lớp, kích thước ẩn 128–256) khai thác thông tin ngữ cảnh theo cả hai hướng kết hợp pooling, dropout, và lớp tuyến tính + softmax với hàm mất mát cross-entropy (có thêm trọng số lớp nếu lệch lớp). Mô hình được tối ưu bằng Adam và dừng sớm dựa trên macro-F1 trên tập dev. Nhóm ưu tiên fastText và có thể so sánh với word2vec nếu điều kiện cho phép.

PhoBERT: Đại diện cho phương pháp sử dụng mô hình ngôn ngữ tiền huấn luyện (dùng phiên bản `PhoBERT-base` qua thư viện Hugging Face).

Nhóm dự kiến fine-tune mô hình bằng cách bổ sung tầng phân loại ba lớp trên biểu diễn [CLS], với tốc độ học 2×10^{-5}, batch size 32, độ dài tối đa 128, huấn luyện trong 3–5 epoch sử dụng mixed precision, nhằm khai thác biểu diễn ngữ cảnh đã học từ dữ liệu tiếng Việt quy mô lớn.

Thiết kế thí nghiệm và phân tích độ nhạy: Để đánh giá ảnh hưởng của tách từ tiếng Việt, nhóm thực hiện thí nghiệm đối chứng giữa đầu vào ở mức âm tiết và mức từ đối với TF-IDF và BiLSTM với 3 random seed (tạo bảng 3×2), đồng thời khảo sát độ nhạy của PhoBERT khi thay đổi quy trình tiền xử lý. Do PhoBERT được tiền huấn luyện trên văn bản đã tách từ, cấu hình tách từ chuẩn được sử dụng làm thiết lập chính; đầu vào không tách từ chỉ phục vụ phân tích xem việc lệch so với dữ liệu tiền huấn luyện làm giảm bao nhiêu điểm.

Để đánh giá khả năng xử lý văn bản thực tế, nhóm dự kiến xây dựng tập kiểm thử bổ sung chứa các biến thể như teencode và văn bản không dấu. Hiệu quả của ba mô hình trên dữ liệu chuẩn và dữ liệu biến thể được so sánh nhằm xác định mức suy giảm chất lượng phân loại.

Hướng mở rộng (ABSA): Nếu tiến độ cho phép, nhóm triển khai phân tích cảm xúc theo khía cạnh sản phẩm sử dụng kiến trúc PhoBERT đa nhiệm với một encoder chung và hai đầu phân loại (chủ đề 4 lớp, cảm xúc 3 lớp), với hàm mất mát $\mathcal{L} = \mathcal{L}_{\text{cảm xúc}} + \lambda \mathcal{L}_{\text{chủ đề}}$, đầu ra là cặp (khía cạnh, cảm xúc). Kết quả sẽ được so sánh với hai mô hình PhoBERT huấn luyện riêng để xem chia sẻ encoder có giúp cải thiện hiệu năng hay không.

4 Cách đánh giá

Chỉ số chính là **macro-F1** (vì lệch lớp), kèm Accuracy, F1 từng lớp và ma trận nhầm lẫn; báo cáo trung bình $\pm$ độ lệch chuẩn qua 3 seed. Siêu tham số chọn trên dev, kết quả test báo cáo một lần. Với phần mở rộng, đo thêm macro-F1 chủ đề và độ chính xác cặp (đúng cả hai nhãn). Phân tích lỗi: lấy mẫu khoảng 100 câu dự đoán sai và phân loại theo nguyên nhân (phủ định, mỉa mai, câu nhiều cảm xúc, nhãn nhiễu).

5 Kế hoạch và phân công

5.1 Kế hoạch thực hiện

Nhóm dự kiến triển khai đề tài trong 6 tuần theo các giai đoạn từ khảo sát dữ liệu, xây dựng mô hình cơ sở, phát triển các mô hình học sâu đến thực nghiệm và hoàn thiện báo cáo. Kế hoạch cụ thể được trình bày trong Bảng 2.

Tuần	Nội dung thực hiện	Sản phẩm dự kiến
1	Khảo sát tài liệu, tìm hiểu dữ liệu, chuẩn bị môi trường và thống nhất phương pháp nghiên cứu.	Proposal, dữ liệu ban đầu.
2	Tiền xử lý dữ liệu, xây dựng baseline TF-IDF + Logistic Regression.	Dữ liệu đã xử lý, kết quả baseline.
3	Cài đặt và huấn luyện BiLSTM, PhoBERT; hoàn thành báo cáo tiến độ.	Mô hình ban đầu, Milestone report.
4	Thực hiện thí nghiệm so sánh, tinh chỉnh siêu tham số.	Bảng kết quả thực nghiệm.
5	Triển khai các hướng mở rộng, phân tích lỗi và trực quan hóa kết quả.	Kết quả mở rộng, bản nháp báo cáo.
6	Tổng hợp kết quả, hoàn thiện báo cáo ACL, slide thuyết trình và kiểm tra demo.	Báo cáo cuối, mã nguồn, slide và demo.

Bảng 2: Kế hoạch triển khai đề tài trong 6 tuần.

5.2 Phân công nhiệm vụ

Nhóm gồm ba thành viên, mỗi người phụ trách một phần chính tương ứng với các hướng tiếp cận của đề tài. Các thành viên phối hợp trong quá trình tích hợp mô hình, đánh giá kết quả và hoàn thiện báo cáo. Phạm vi công việc và sản phẩm dự kiến của từng thành viên được trình bày trong Bảng 3.

Thành viên	Nhiệm vụ phụ trách	Sản phẩm dự kiến
Hoàng Vũ	Thu thập, khám phá và tiền xử lý dữ liệu; thực hiện tách từ; xây dựng baseline TF-IDF + Logistic Regression.	Dữ liệu đã xử lý; mã tiền xử lý; script đánh giá; kết quả baseline.
Kế Toàn	Xây dựng ma trận embedding; tự cài đặt mô hình BiLSTM bằng PyTorch; huấn luyện và thực hiện các thí nghiệm ablation.	Mã nguồn BiLSTM; cấu hình huấn luyện; log thực nghiệm; kết quả ablation.
Văn Tùng	Fine-tune PhoBERT; triển khai mô hình mở rộng theo cấu trúc nhãn của bộ dữ liệu; thực hiện phân tích lỗi và trực quan hóa kết quả.	Mã nguồn fine-tuning; kết quả thực nghiệm; hình ảnh và bảng phân tích; demo.

Bảng 3: Phân công nhiệm vụ và sản phẩm dự kiến của các thành viên.